گزارش فنی این پروژه نشان می‌دهد که استخراج متن از پرونده‌های دارای نوشتار راست‌به‌چپ نیازمند توجه ویژه‌ای است. هنگامی که یک بند طولانی در چند سطر شکسته می‌شود، ترتیب سطرها و واژه‌ها باید دقیقاً مطابق با متن منطقی نویسنده بازسازی شود تا خواننده بتواند مطلب را بدون ابهام دنبال کند.

بند دوم کوتاه‌تر است؛ اما همچنان شامل نشانه‌های نگارشی مانند ویرگول، نقطه‌ویرگول و پرسش است. آیا همه‌ی این نشانه‌ها در جای درست خود باقی می‌مانند؟

گزارش سالانه فعالیت‌ها

۱. مقدمه

در سال گذشته چندین پروژه پژوهشی با موفقیت به پایان رسید و نتایج آن‌ها در نشریات معتبر منتشر شد.

۲. روش‌ها

داده‌ها از طریق پرسش‌نامه گردآوری و سپس با نرم‌افزار آماری تحلیل شدند.

فهرست کارهای هفته

1. تهیه‌ی پیش‌نویس گزارش
2. بازبینی جدول‌ها و نمودارها
3. ارسال نسخه‌ی نهایی به کمیته

نام	شهر	تعداد
علی	تهران	۱۲
مریم	شیراز	۳۴
رضا	تبریز	۵۶

برای نصب بسته کافی است دستور pip install markitdown را اجرا کنید و سپس نسخه‌ی Python 3.12 را بررسی نمایید. نشانی مخزن کد https://github.com/microsoft/markitdown است و گزارش خطا را می‌توانید به bugs@example.com ارسال کنید.

ستون نخست شامل چند جمله‌ی نسبتاً بلند است تا متن در همین ستون ادامه یابد و به ستون دوم نرسد. این جمله برای پر کردن فضا نوشته شده است.

ستون دوم با بند دیگری آغاز می‌شود که باید پس از پایان ستون نخست خوانده شود، نه همزمان با آن.

در روزنامه‌ها و مجله‌ها معمولاً فاصله‌ی میان ستون‌ها کم است و خواننده تنها با یک شکاف باریک متن را از هم جدا می‌بیند. بازسازی ترتیب خواندن در چنین صفحه‌هایی باید ابتدا ستون راست را کامل بخواند.

سپس نوبت به ستون چپ می‌رسد که همان بند بعدی را ادامه می‌دهد و نباید با سطرهای ستون نخست درهم بیامیزد.

عنوان صفحه

متن اصلی صفحه در اینجا قرار دارد و پایین صفحه شماره‌ی آن آمده است.

او گفت: «این روش ۲۵٪ سریع‌تر است (طبق آزمایش‌ها)». سپس افزود: «نتیجه در جدول ۳ آمده است؛ لطفاً بررسی کنید.»

رابطه $x + 3 = 9$ برقرار است و مقدار $a + b$ نیز درست است. هر دو در فایل report_v2.pdf آمده‌اند.

ارزیابی عملکرد سامانه

سامانه‌ی جدید در سه مرحله ارزیابی شد. در مرحله‌ی نخست، نمونه‌هایی از متن فارسی با طول‌های گوناگون تهیه شد و خروجی هر نمونه با متن مرجع مقایسه گردید. در این مرحله ۹۸٫۵ درصد واژه‌ها بدون خطا بازسازی شدند.

در مرحله‌ی دوم، پرونده‌هایی با جدول و ستون‌های متعدد بررسی شد و نتایج نشان داد که ترتیب خواندن در بیشتر موارد درست است. با این حال، چند مورد استثنا باقی ماند که در بخش بعد توضیح داده می‌شود.

در مرحله‌ی سوم، سرعت پردازش اندازه‌گیری شد؛ میانگین زمان برای هر صفحه حدود ۰٫۱۲ ثانیه بود و حافظه‌ی مصرفی تغییر چشمگیری نکرد.